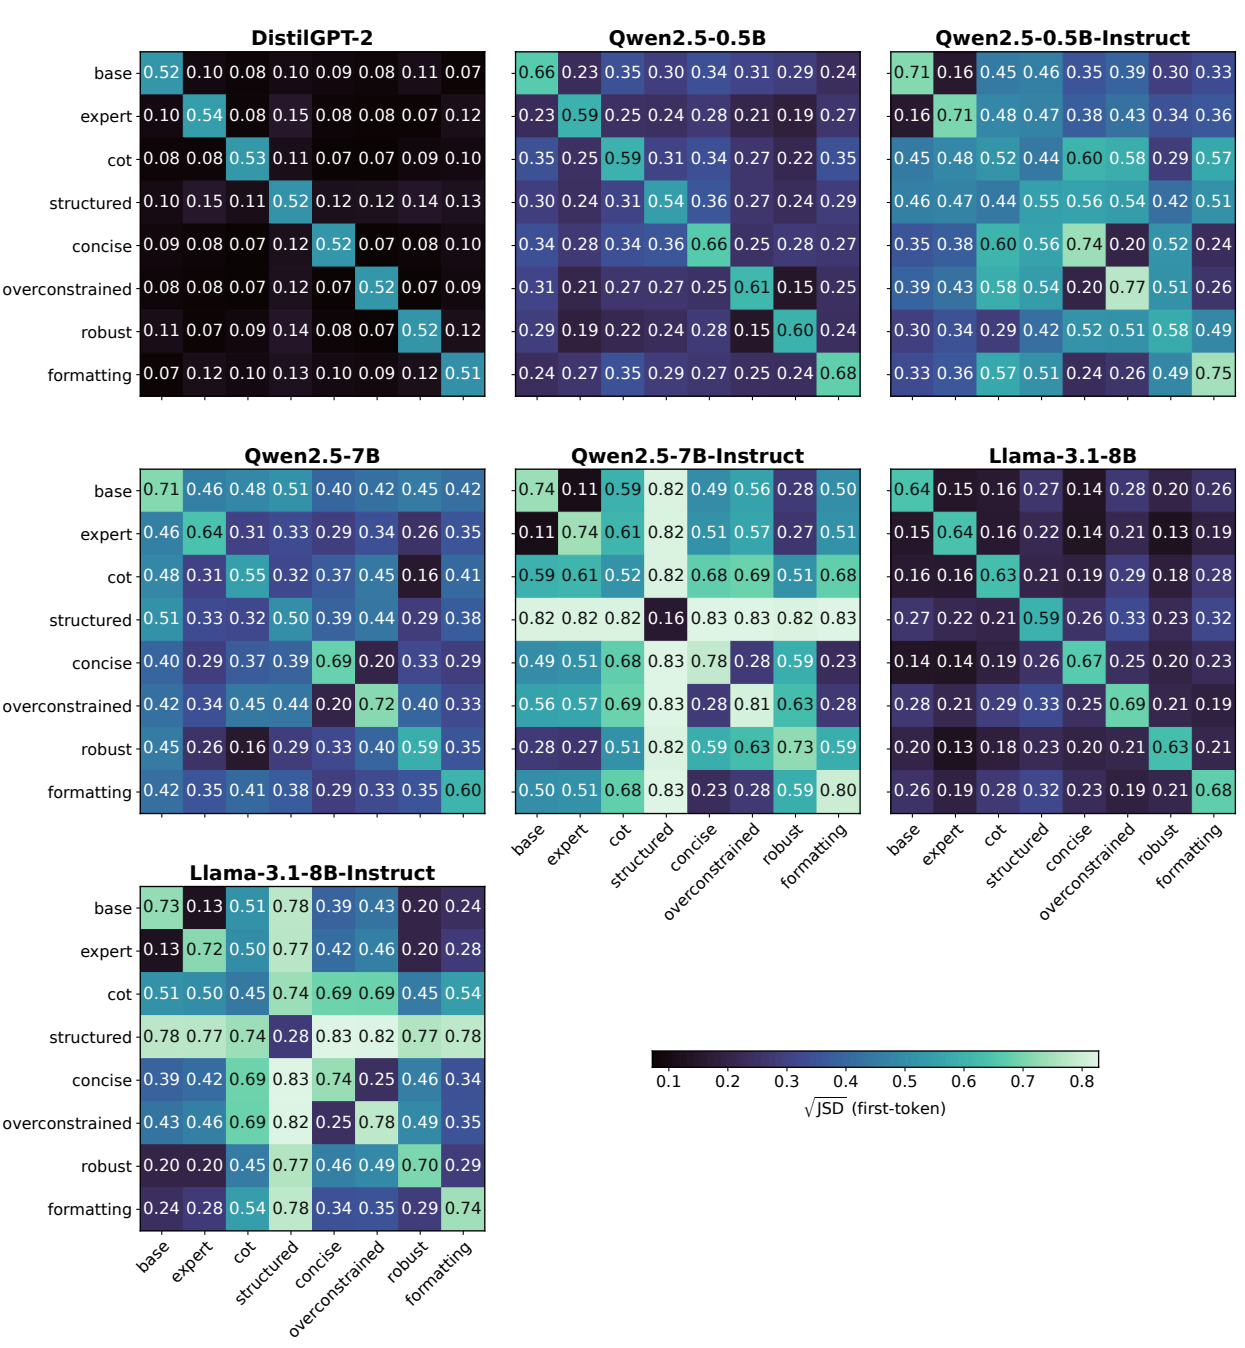
DistilGPT-2
base 0.52 0.10 0.08 0.10 0.09 0.08 0.11 0.07
expert 0.10 0.54 0.08 0.15 0.08 0.08 0.07 0.12
cot 0.08 0.08 0.53 0.11 0.07 0.07 0.09 0.10
structured 0.10 0.15 0.11 0.52 0.12 0.12 0.14 0.13
concise 0.09 0.08 0.07 0.12 0.52 0.07 0.08 0.10
overconstrained 0.08 0.08 0.07 0.12 0.07 0.52 0.07 0.09
robust 0.11 0.07 0.09 0.14 0.08 0.07 0.52 0.12
formatting 0.07 0.12 0.10 0.13 0.10 0.09 0.12 0.51
Qwen2.5-0.5B
0.66 0.23 0.35 0.30 0.34 0.31 0.29 0.24
0.23 0.59 0.25 0.24 0.28 0.21 0.19 0.27
0.35 0.25 0.59 0.31 0.34 0.27 0.22 0.35
0.30 0.24 0.31 0.54 0.36 0.27 0.24 0.29
0.34 0.28 0.34 0.36 0.66 0.25 0.28 0.27
0.31 0.21 0.27 0.27 0.25 0.61 0.15 0.25
0.29 0.19 0.22 0.24 0.28 0.15 0.60 0.24
0.24 0.27 0.35 0.29 0.27 0.25 0.24 0.68
Qwen2.5-0.5B-Instruct
0.71 0.16 0.45 0.46 0.35 0.39 0.30 0.33
0.16 0.71 0.48 0.47 0.38 0.43 0.34 0.36
0.45 0.48 0.52 0.44 0.60 0.58 0.29 0.57
0.46 0.47 0.44 0.55 0.56 0.54 0.42 0.51
0.35 0.38 0.60 0.56 0.74 0.20 0.52 0.24
0.39 0.43 0.58 0.54 0.20 0.77 0.51 0.26
0.30 0.34 0.29 0.42 0.52 0.51 0.58 0.49
0.33 0.36 0.57 0.51 0.24 0.26 0.49 0.75
Qwen2.5-7B
base 0.71 0.46 0.48 0.51 0.40 0.42 0.45 0.42
expert 0.46 0.64 0.31 0.33 0.29 0.34 0.26 0.35
cot 0.48 0.31 0.55 0.32 0.37 0.45 0.16 0.41
structured 0.51 0.33 0.32 0.50 0.39 0.44 0.29 0.38
concise 0.40 0.29 0.37 0.39 0.69 0.20 0.33 0.29
overconstrained 0.42 0.34 0.45 0.44 0.20 0.72 0.40 0.33
robust 0.45 0.26 0.16 0.29 0.33 0.40 0.59 0.35
formatting 0.42 0.35 0.41 0.38 0.29 0.33 0.35 0.60
Qwen2.5-7B-Instruct
0.74 0.11 0.59 0.82 0.49 0.56 0.28 0.50
0.11 0.74 0.61 0.82 0.51 0.57 0.27 0.51
0.59 0.61 0.52 0.82 0.68 0.69 0.51 0.68
0.82 0.82 0.82 0.16 0.83 0.83 0.82 0.83
0.49 0.51 0.68 0.83 0.78 0.28 0.59 0.23
0.56 0.57 0.69 0.83 0.28 0.81 0.63 0.28
0.28 0.27 0.51 0.82 0.59 0.63 0.73 0.59
0.50 0.51 0.68 0.83 0.23 0.28 0.59 0.80
Llama-3.1-8B
0.64 0.15 0.16 0.27 0.14 0.28 0.20 0.26
0.15 0.64 0.16 0.22 0.14 0.21 0.13 0.19
0.16 0.16 0.63 0.21 0.19 0.29 0.18 0.28
0.27 0.22 0.21 0.59 0.26 0.33 0.23 0.32
0.14 0.14 0.19 0.26 0.67 0.25 0.20 0.23
0.28 0.21 0.29 0.33 0.25 0.69 0.21 0.19
0.20 0.13 0.18 0.23 0.20 0.21 0.63 0.21
0.26 0.19 0.28 0.32 0.23 0.19 0.21 0.68
base expert cot structured concise overconstrained robust formatting
Llama-3.1-8B-Instruct
base 0.73 0.13 0.51 0.78 0.39 0.43 0.20 0.24
expert 0.13 0.72 0.50 0.77 0.42 0.46 0.20 0.28
cot 0.51 0.50 0.45 0.74 0.69 0.69 0.45 0.54
structured 0.78 0.77 0.74 0.28 0.83 0.82 0.77 0.78
concise 0.39 0.42 0.69 0.83 0.74 0.25 0.46 0.34
overconstrained 0.43 0.46 0.69 0.82 0.25 0.78 0.49 0.35
robust 0.20 0.20 0.45 0.77 0.46 0.49 0.70 0.29
formatting 0.24 0.28 0.54 0.78 0.34 0.35 0.29 0.74
base expert cot structured concise overconstrained robust formatting
0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8
√JSD (first-token)